

Sistema Multi-Agente para Análisis de Deserción Estudiantil

Proyecto Final — Inteligencia Artificial · Universidad EAFIT · 2026-1

Juan José Restrepo jjrestrepc@eafit.edu.co
Samuel Cadavid Zapata scadavidz@eafit.edu.co

Mayo 2026

Resumen

Se presenta un sistema multi-agente para predecir deserción estudiantil universitaria y generar reportes ejecutivos automáticos. Sobre el dataset UCI de Portugal ($n=4,424$ estudiantes, 36 variables), se construyó un pipeline que integra modelado con *machine learning* (Random Forest, AUC-ROC = 0,9335, F1 = 0,7879) con un sistema de cuatro agentes orquestado en LangGraph que combina recuperación aumentada por generación (RAG) sobre literatura científica para producir reportes ejecutivos accionables. El módulo RAG obtuvo 100 % de exactitud en un conjunto de diez preguntas de evaluación.

1. Introducción

La deserción universitaria afecta a más del 40 % de los estudiantes en América Latina [7], con impacto directo en la sostenibilidad institucional y el desarrollo profesional de los individuos. La detección temprana mediante modelos predictivos, combinada con generación automática de reportes, representa una oportunidad concreta para que las instituciones actúen de forma preventiva.

Este trabajo responde a la pregunta: *¿Puede un sistema multi-agente predecir la deserción estudiantil con métricas sólidas y generar reportes ejecutivos enriquecidos con contexto bibliográfico?* Las contribuciones son: (1) un pipeline ML reproducible sin *data leakage* con AUC-ROC = 0,9335; (2) cuatro agentes LangGraph bajo patrón *fan-out* paralelo; (3) un módulo RAG sobre cinco documentos científicos con 100 % de exactitud; y (4) una aplicación Streamlit que integra todo el sistema.

2. Datos y Análisis Exploratorio

2.1. Dataset y partición

Se utilizó el dataset *Predict Students' Dropout and Academic Success* [6] (UCI, id = 697): 4,424 estudiantes, 36 variables académicas, socioeconómicas y demográficas. La variable objetivo se binarizó: $y=1$ (Dropout) vs. $y=0$ (Graduate/Enrolled). La tasa de deserción es 32.1 %, lo que genera desbalance y justifica el uso de F1 y AUC-ROC como métricas principales (Figura 1). El dataset se dividió estratificadamente en 70 % entrenamiento (3,096), 15 % validación (664) y 15 % test (664), **antes** de cualquier transformación para evitar *data leakage*.




Figura 1: Distribución de la variable objetivo. La clase minoritaria (Dropout, 32.1 %) justifica el uso de métricas F1 y AUC-ROC.

2.2. Hallazgos principales

El dataset no presenta valores nulos. El análisis de correlaciones (Figura 2) confirma que las variables académicas del primer y segundo semestre —unidades aprobadas y calificaciones— son los predictores más fuertes. Las variables socioeconómicas (*Tuition fees up to date*, *Debtor*, *Scholarship holder*) actúan como factores de riesgo secundarios [2].




Figura 2: Correlación de las 14 variables más relevantes con Dropout. Las unidades curriculares aprobadas dominan el ranking.

3. Arquitectura del Sistema Multi-Agente

El sistema combina un modelo ML clásico con un pipeline de cuatro agentes orquestado en LangGraph [4]. El patrón de ejecución es *fan-out* paralelo: los agentes EDA y RAG corren simultáneamente, el agente ML actúa como barrera de sincronización (*join*), y el sintetizador produce el reporte final (Figura 3).




Figura 3: Arquitectura fan-out: EDA y RAG corren en paralelo; ML es la barrera de join.

Cada agente usa el LLM `llama-3.1-8b-instant` vía Groq [3] (`temperature = 0,2`) con prompts que inyectan datos reales del sistema para minimizar alucinaciones. Los roles son:

Cuadro 1: Descripción de los cuatro agentes.

Agente	Función
EDA	Interpreta estadísticos reales del dataset e identifica variables de riesgo.
RAG	Recupera fragmentos de cinco papers desde ChromaDB y genera síntesis bibliográfica.
ML	Interpreta métricas del Random Forest y recomienda mejoras.
Sintetizador	Integra los tres análisis en un reporte ejecutivo estructurado.

El módulo RAG [1] indexa cinco documentos sobre deserción (Tinto, factores académicos, socioeconómicos, enfoques ML y sistemas de alerta temprana) en ChromaDB con embeddings `all-MiniLM-L6-v2` (local, gratuito). En cada consulta se recuperan los cuatro fragmentos más relevantes por similitud coseno.

4. Resultados

4.1. Comparación de modelos

Se entrenaron tres modelos dentro de pipelines `scikit-learn` con `StandardScaler` (ajustado solo en entrenamiento) y `class_weight='balanced'`. La Tabla 2 resume las métricas en validación; el Random Forest fue seleccionado por mayor AUC-ROC.

Cuadro 2: Comparación en validación. Baseline: `DummyClassifier` (clase mayoritaria).

Modelo	F1 (Dropout)	AUC-ROC	Avg Precision
Dummy (baseline)	0.0000	0.5000	0.3210
Logistic Regression	0.7200	0.8734	0.8102
Gradient Boosting	0.7821	0.9289	0.8844
Random Forest	0.7879	0.9335	0.8956

4.2. Evaluación en test set

El modelo ganador se evaluó una única vez en el test set. Las métricas finales son: $F1 = 0,7879$, $AUC-ROC = 0,9335$, $Precisión = 0,8525$, $Recall = 0,7324$, $Avg\ Precision = 0,8956$. El AUC-ROC supera el rango típico reportado en la literatura (0.85–0.93) [5]. La Figura 4 muestra la matriz de confusión, la curva ROC y la curva Precision-Recall; la Figura 5 presenta las variables más predictivas.




Figura 4: Evaluación final en test set: matriz de confusión, curva ROC (AUC = 0,9335) y curva PR (AP = 0,8956).




Figura 5: Top 15 variables según importancia del Random Forest. Las unidades aprobadas del 2.º semestre encabezan el ranking.

4.3. Evaluación del módulo RAG

Se construyó un conjunto de diez preguntas con respuestas verificables a partir del corpus y los datos reales del sistema (tasas de deserción, variables predictivas, modelos reportados en la literatura). El sistema respondió correctamente las diez preguntas (100%), tal como muestra la Figura 6.




Figura 6: Evaluación cuantitativa del RAG: 10/10 preguntas correctas.

5. Conclusiones

El sistema demuestra que es posible combinar ML clásico de alto rendimiento (AUC-ROC = 0,9335) con agentes LLM que enriquecen el análisis con literatura científica, todo con herramientas gratuitas y de código abierto. El patrón *fan-out* de LangGraph permite una arquitectura limpia y extensible. El módulo RAG obtiene 100 % de exactitud en la evaluación, validando la cobertura temática del corpus.

Como limitaciones: el conjunto de evaluación RAG es pequeño (10 preguntas) y el dataset proviene de Portugal, lo que puede limitar su transferibilidad a contextos latinoamericanos. Como trabajo futuro se propone incorporar SMOTE para mejorar el recall (73.2 %), expandir el corpus con papers en español, y desplegar la app en Streamlit Cloud o HuggingFace Spaces.

Referencias

- [1] Chroma. Chroma: The open-source embedding database, 2023. Versión 0.5.5.
- [2] Dursun Delen. A comparative analysis of machine learning techniques for student retention management. *Decision Support Systems*, 49(4):498–506, 2010.
- [3] Groq Inc. Groq api: Fast ai inference, 2024. Modelo: llama-3.1-8b-instant.
- [4] LangChain AI. LangGraph: Building stateful, multi-actor applications with llms, 2024. Versión 0.2.28.
- [5] Naomie Mduma, Khamisi Kalegele, and Davis Machuve. A survey of machine learning approaches and techniques for student dropout prediction. *Data Science Journal*, 18(1):14, 2019.
- [6] Valentim Realinho, Jorge Machado, Luís Baptista, and Mónica V. Martins. Predicting student dropout and academic success. *Data*, 7(11):146, 2022.
- [7] Vincent Tinto. *Leaving College: Rethinking the Causes and Cures of Student Attrition*. University of Chicago Press, Chicago, IL, 1987.